Topic 5 & 6 - Assignment

Hands-On Python 2

Ama Febriyanti
Universitas Negeri Malang

01

Dataset Telco Churn

Missing Values Checking

Missing values terjadi ketika tidak ada data yang terdeteksi, biasanya muncul sebagai “NaN”, “?”, atau tidak ada nilainya sama sekali (*blank cell*). Adapun langkah-langkah untuk melakukan missing values checking adalah sebagai berikut.

- Langkah pertama adalah mengimport, menjalankan dan membaca data. Di sini saya mengimport data berbentuk csv ke repository github terlebih dahulu, kemudian mengimportnya dengan menempelkan link raw dari github. Setelah itu sebelum cleansing, saya membaca shape data sebagai berikut:

```
[ ] import pandas as pd
    df=pd.read_csv('https://raw.githubusercontent.com/amafeb/amafeb.github.io/master/WA_Fn-UseC_-Telco-Customer-Churn.csv')

[ ] df.shape

    (7043, 21)
```

Missing Values Checking

- Langkah kedua yaitu membaca sampel data dan type data sebagai berikut:

```
df.head()
```

	customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService
0	7590-VHVEG	Female	0	Yes	No	1	No
1	5575-GNVDE	Male	0	No	No	34	Yes
2	3668-QPYBK	Male	0	No	No	2	Yes
3	7795-CFOCW	Male	0	No	No	45	No
4	9237-HQITU	Female	0	No	No	2	Yes

5 rows × 21 columns

```
df.dtypes
```

```
customerID            object
gender                object
SeniorCitizen          int64
Partner               object
Dependents            object
tenure                 int64
PhoneService          object
MultipleLines         object
InternetService       object
OnlineSecurity        object
OnlineBackup          object
DeviceProtection      object
TechSupport           object
StreamingTV           object
StreamingMovies       object
Contract              object
PaperlessBilling      object
PaymentMethod         object
MonthlyCharges       float64
TotalCharges          object
Churn                 object
dtype: object
```

Missing Values Checking

- Langkah selanjutnya yang merupakan inti adalah memeriksa apakah terdapat missing value atau tidak dengan melihat null values menggunakan syntax sebagai berikut:

```
df.isnull().sum()
```

```
customerID          0
gender              0
SeniorCitizen       0
Partner             0
Dependents          0
tenure              0
PhoneService        0
MultipleLines       0
InternetService     0
OnlineSecurity      0
OnlineBackup        0
DeviceProtection    0
TechSupport         0
StreamingTV         0
StreamingMovies     0
Contract            0
PaperlessBilling    0
PaymentMethod       0
MonthlyCharges      0
TotalCharges        0
Churn               0
dtype: int64
```

```
[ ] df.isnull().sum().sum()
```

```
0
```

- Dari sini dapat dilihat bahwa tidak terdapat satupun missing value pada data.

Categorical Data Encoding

Untuk categorical data encoding saya menggunakan pendekatan *one hot encoding* yang mengubah setiap nilai kategori menjadi kolom baru dan memberikan nilai 1 atau 0 (Benar/Salah) ke kolom tersebut. Adapun syntax yang saya gunakan adalah sebagai berikut:

```
pd.get_dummies(df).shape
```

```
(7043, 13620)
```

```
[ ] pd.get_dummies(df)
```

	SeniorCitizen	tenure	MonthlyCharges	customerID_0002-ORFBO	customerID_0003-MKNFE	customerID_0004-TLHLJ	customerID_0011-IGKFF	customerID_0013-EXCHZ	customerID_0013-MHZWF	customerID
0	0	1	29.85	0	0	0	0	0	0	
1	0	34	56.95	0	0	0	0	0	0	
2	0	2	53.85	0	0	0	0	0	0	
3	0	45	42.30	0	0	0	0	0	0	
4	0	2	70.70	0	0	0	0	0	0	
...	...	...	...	...	...	...	...	...	...	
7038	0	24	84.80	0	0	0	0	0	0	
7039	0	72	103.20	0	0	0	0	0	0	
7040	0	11	29.60	0	0	0	0	0	0	
7041	1	4	74.40	0	0	0	0	0	0	

Are Instagram users

Anomalies and Outlier Handling

Dalam menemukan anomalies dan outlier, saya menggunakan basic outlier formula sebagai berikut:

```
[ ] Q1 = df['MonthlyCharges'].quantile(0.25)
    Q3 = df['MonthlyCharges'].quantile(0.75)
    IQR = Q3-Q1
    upper_bound = Q3 + (1.5*IQR)
    lower_bound = Q1 - (1.5*IQR)
```

```
[ ] upper_bound
```

```
171.375
```

```
[ ] lower_bound
```

```
-46.02499999999999
```

Anomalies and Outlier Handling

Apabila data lebih besar dari upper_bound atau lebih kecil dari lower_bound, maka data tersebut termasuk dalam outlier. Dari, formula yang saya jalankan, diketahui bahwa tidak terdapat outlier dalam data telco churn.

```
[35] outliers = df[df['MonthlyCharges']>upper_bound]
     outliers
```

customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	...	DeviceProtection	TechSupport

0 rows × 21 columns

```
[36] outliers = df[df['MonthlyCharges']<lower_bound]
     outliers
```

customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	...	DeviceProtection	TechSupport

0 rows × 21 columns

Link Google Colab:

https://colab.research.google.com/drive/1EldMjJ0G450QTH3_BmcplN1Qlgi9YTce?usp=sharing

02 Topic 6 Assignment

Link Google Colab:

https://colab.research.google.com/drive/1loKwkYwlMsn7tUnEkkCosxh4CH3ZHFEG?usp=sharing

Thanks
26700
34500
97633
67888